Pre-entrega Módulo 5 — RAG: el agente responde con el manual de soporte

Bruno Acorsi · Coderhouse, AI Automation Avanzado · Manager `checkpoint5_bruno_acorsi` + workers `*_modulo5_acorsi_bruno` + herramienta `rag_consultar_manual_modulo5_acorsi_bruno`

Qué se construyó

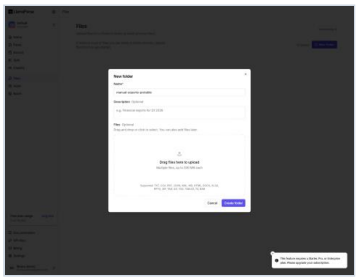
El sistema multi-agente del M4 (router + 3 especialistas + memoria + CRM/Gmail/Slack) suma una **base de conocimiento real**: el **Manual de soporte de ProTable v1.0** (14 páginas, 15 capítulos, 91 subsecciones, armado solo con fuentes reales del producto). Los tres especialistas (Billing, Tech Support y Sales) tienen la herramienta `consultar_manual_protable` y responden **solo con lo que dicen los fragmentos recuperados**, citando la sección. Si el manual no trae la respuesta, dicen literalmente **"No sé"** y el caso pasa a una persona.

Email (Gmail) o Chat de pruebas → Memoria por Session_ID → Router (gpt-4o-mini) →
Worker Billing / Tech / Sales (gpt-4o-mini) ⇄ consultar_manual_protable → Normalizar salida (guardias) →
Log + memoria + CRM / borrador / Slack

Ingesta (una vez): PDF → LlamaParse (LlamaCloud) → chunking por títulos numerados (91) →
embeddings OpenAI text-embedding-3-small → tabla `rag_manual_protable_m5`

Decisión técnica: dónde viven los vectores

> La consigna propone el índice de LlamaCloud. Lo intenté por la interfaz y por la API: en el **plan gratuito el Index exige carpetas** ("*This feature requires a Starter, Pro, or Enterprise plan*", HTTP 403 en `/api/v1/beta/directories`) y el índice anterior (*Pipelines*) ya no se puede crear en organizaciones nuevas (403 "*Use an Index instead*").
> **Solución:** LlamaCloud se usa para lo que el plan gratis permite y es lo central de la consigna — **subir y parsear el documento maestro con jerarquía y tablas** (LlamaParse, 42 créditos) — y la recuperación se implementa en n8n como un **sub-workflow-herramienta** con Top-K y Minimum Score propios. La interfaz con los agentes es la misma que tendría el índice de LlamaCloud: si se contrata el plan Starter (USD 50/mes), solo cambia el interior del sub-workflow (evidencia: aviso de LlamaCloud al crear la carpeta, abajo). Ventaja lateral: el nodo de LlamaCloud para n8n trae Top-K pero **no** Minimum Score; acá los dos se controlan.



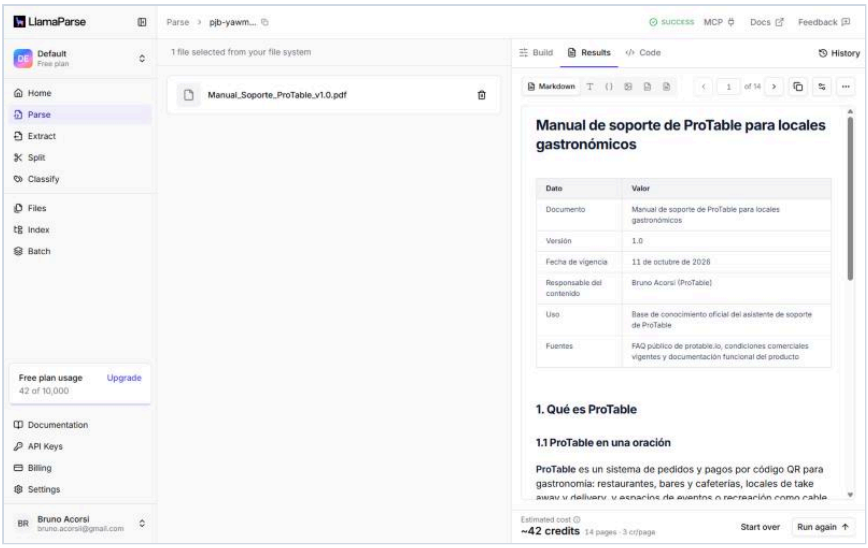
Aviso de LlamaCloud al crear la carpeta del índice con el plan gratuito: "This feature requires a Starter, Pro, or Enterprise plan".

Workflows entregados (carpeta M5 de n8n, exportados en el repo)

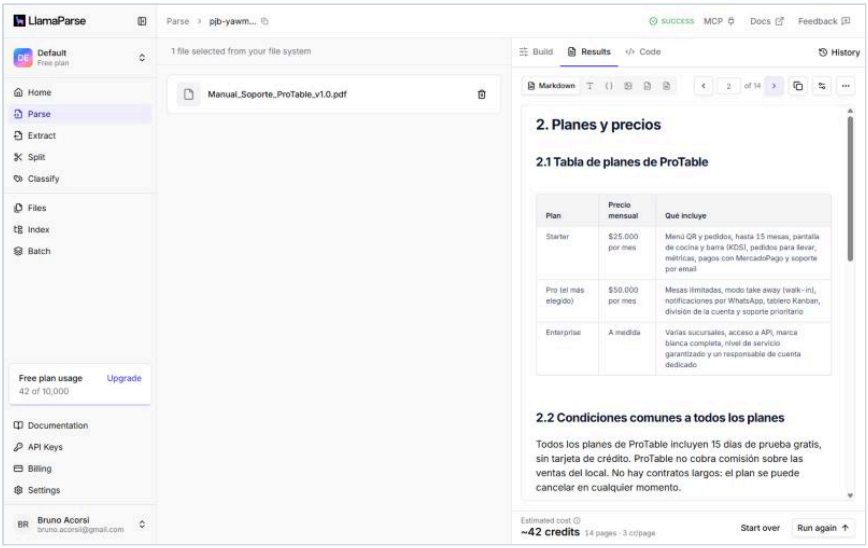
Workflow	Rol
`checkpoint5_bruno_acorsi`	Manager: copia del M4 + workers M5 + Chat Trigger de pruebas (el chat no toca HubSpot ni Gmail). Router con taxonomía ampliada: las consultas sobre cómo funciona ProTable o su soporte van a Tech Support (antes caían en UNKNOWN y nunca llegaban al manual).
`worker1/2/3_*_modulo5_acorsi_bruno`	Especialistas con la herramienta RAG, OpenAI gpt-4o-mini (reemplaza a `qwen3.8-27b`, que en Groq es un modelo *Preview*), y salida con `fuentes`, `consultas_rag` y `fragmentos` para auditoría y para el juez del M8.

`rag_consultar_manual_modulo5_acorsi_bruno`	Herramienta de recuperación: embebe la consulta, la compara con los 91 fragmentos y devuelve Top-K 4 con Minimum Score 0,40.
`M5_ingesta_manual_llamacloud`	Ingesta re-ejecutable: vacía la tabla, parsea el PDF con LlamaParse, trocea, embebe y guarda (ejecución 173).

Pieza 1 · Captura 1 — El documento maestro parseado en LlamaCloud



Página 1 del resultado: título del documento, tabla de metadatos en celdas y jerarquía 1 → 1.1.



Página 2: la tabla de planes y precios quedó en filas y columnas (plan · precio · qué incluye).

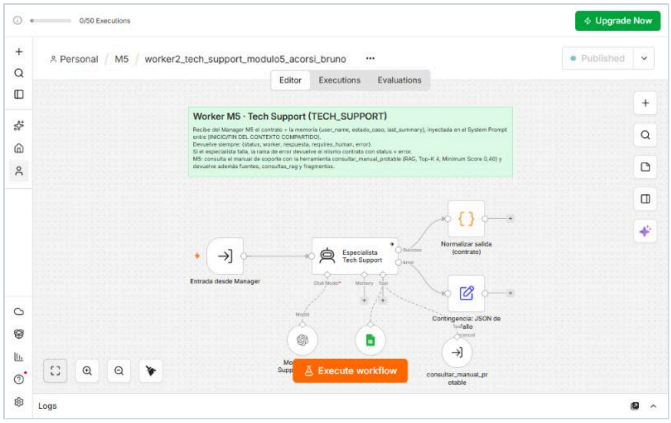
LlamaParse (LlamaCloud) · job `pjb-yawm1r1qc05m3yt9ovikz09ekquz` · `Manual_Soporte_ProTable_v1.0.pdf` · 14 páginas · tier Cost Effective · 42 créditos · SUCCESS.

Qué se verificó del parseo

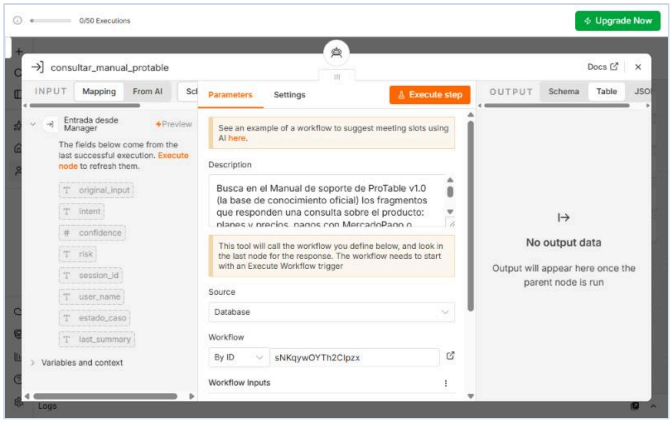
Control	Resultado	Cómo se usó
Tablas en celdas	Correcto	Las 8 tablas del manual (metadatos, planes, estados del pedido, modos de dividir la cuenta, etc.) salen como tablas, no como texto corrido: el agente puede leer "Starter · $25.000 por mes · hasta 15 mesas" sin mezclar columnas.
Títulos y numeración	Todos presentes	Los 15 capítulos y las 91 subsecciones aparecen con su número (1.1 … 15.3).
Nivel de los títulos (#, ##, ###)	Inconsistente	LlamaParse decide el nivel página por página: "3.6 Propinas" sale como `#` y "3.5" como `###`. Por eso el **chunking no usa el nivel** sino la **numeración** (regex `N.M`): 1 fragmento por subsección, con el capítulo y el título como encabezado del fragmento.
Tamaño de los fragmentos	55 a 455 tokens	91 fragmentos; ninguno corta una tabla a la mitad. Cada fragmento empieza con "*Manual de soporte de ProTable v1.0 · capítulo · Sección N.M título*" para que el embedding sepa de qué trata.

El texto parseado completo y el código del chunking se guardaron como evidencia (la consola de LlamaCloud conserva el resultado solo 48 horas).

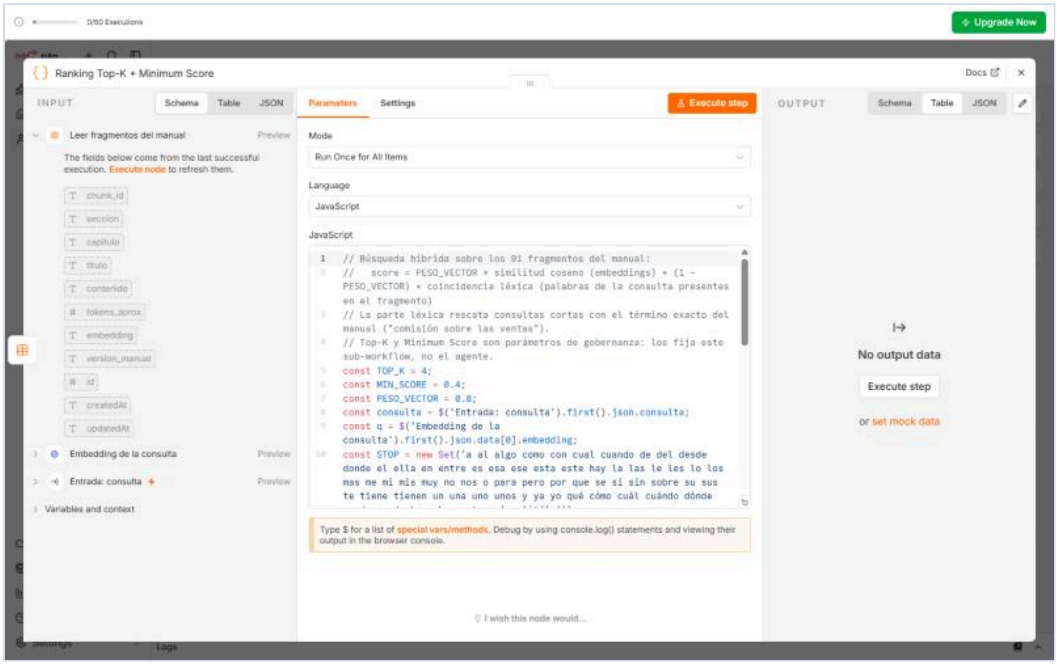
Pieza 2 · Captura 2 — Herramienta de recuperación en el AI Agent, con Top-K y Minimum Score



El AI Agent (Tools Agent) del especialista con la herramienta `consultar_manual_protable` conectada en **Tool** (además de `registrar_ticket`).



La herramienta: descripción de negocio para el agente y el sub-workflow que ejecuta (`rag_consultar_manual_modulo5`, id sNKq…).



Nodo "Ranking Top-K + Minimum Score" del sub-workflow `rag_consultar_manual_modulo5_acorsi_bruno`: `TOP_K = 4`, `MIN_SCORE = 0.4`, `PESO_VECTOR = 0.8`. Los fija el sub-workflow, no el agente (gobernanza).

Top-K = 4

La sección que responde no siempre sale 1.ª: en las pruebas ciegas la 3.2 salió 3.ª (pregunta 1) y la 8.2 salió 3.ª (pregunta 3), y la respuesta usa las dos secciones. Con K = 4 entran la sección útil y sus vecinas sin llenar el prompt (≈ 600 tokens). Recuperación medida con las consultas tal cual las escribiría un usuario: 14 de 16 traen la sección correcta 1.ª; las 2 que fallan ("porcentaje de lo que vendo", "bajarse alguna app") las rescata la reformulación del agente.

Minimum Score = 0,40

Calibrado con 27 consultas (16 que el manual responde y 11 que no). El acierto más flojo dio 0,44; ruido como "capital de Francia" (0,10), "reintegro si me doy de baja" (0,31) o "factura electrónica" (0,34) queda debajo y la herramienta devuelve `sin_resultados = true`.

Por qué búsqueda híbrida (0,8 semántica + 0,2 léxica)

Con solo embeddings, la consulta que escribió el agente, "*comisión sobre las ventas*", daba 0,34 contra la sección 2.2, que dice casi literal "ProTable no cobra comisión sobre las ventas": quedaba bajo el corte y el agente contestaba "No sé" a una pregunta que el manual sí responde. Sumando 20 % de coincidencia de palabras (raíces de 5 letras, sin palabras vacías) pasa a 0,44 y sale 1.ª. Con 30 % léxico, "mesa no habilitada" se iba a secciones que dicen "habilitado" en otro sentido; 20 % fue el equilibrio.

Consulta (ejecución 305)	Tipo	Mejor sección	Score	¿Pasa 0,40?
comisión sobre las ventas	En el manual	2.2	0,44	Sí
¿se puede partir la cuenta entre varios amigos?	En el manual	8.1	0,46	Sí
a qué cuenta va el dinero de MercadoPago	En el manual	13.2	0,77	Sí
reintegro por cancelación de la suscripción	Fuera	2.2	0,35	No → "No sé"
¿en cuánto tiempo me responden un reclamo?	Fuera	15.2	0,28	No → "No sé"
¿qué horario de atención tiene el soporte?	Fuera	15.2	0,50	Sí: lo frena el prompt

Lectura honesta del umbral: el Minimum Score **no alcanza solo**. Preguntas fuera del manual pero con vocabulario del dominio (horario del soporte, integración con Rappi, factura electrónica escrita como pregunta) superan 0,40 porque se parecen a secciones reales. Por eso hay **dos capas**: el umbral filtra el ruido y la regla "No sé" del System Prompt (Pieza 3) decide si los fragmentos responden *exactamente* lo preguntado. Subir el umbral a 0,50 para atajar esos casos dejaba afuera respuestas válidas (comisión 0,44, partir la cuenta 0,46).

Pieza 3 · Captura 3 — System Prompt RAG (100 % basado en fuentes + regla "No sé")



Bloque [FUENTE DE VERDAD]: consultar siempre, reformular con el vocabulario del manual, responder solo con los fragmentos, citar la sección.



Regla "No sé" literal, con ejemplos de lo que el manual no informa, y regla fiscal: no ofrecer facturación electrónica, que el producto no tiene.

```
[FUENTE DE VERDAD: MANUAL DE SOPORTE DE PROTABLE v1.0]
- Todo lo que digas sobre cómo funciona ProTable tiene que salir de la herramienta consultar_manual_protable.
Llamala SIEMPRE, en este mismo turno.
- Escribí la consulta con el vocabulario del manual ("comisión sobre las ventas" en vez de "porcentaje de lo
que vendo"). Máximo 2 consultas por turno.
- Respondé SOLO con lo que dicen los fragmentos devueltos. Citá la sección: "(Manual de soporte, sección 2.1)".
- Regla "No sé": si sin_resultados = true o ningún fragmento responde EXACTAMENTE lo que se pregunta, la
respuesta completa es:
  "No sé: esa información no está en el manual de soporte de ProTable. Tu caso pasa a una persona del equipo,
que lo va a revisar."
  y requires_human = true. Que un fragmento hable del mismo tema NO alcanza para responder otra pregunta.
```

Guardias determinísticas (nodo "Normalizar salida", fuera del modelo)

El prompt solo no garantizó el comportamiento; estas reglas en código lo aseguran aunque el modelo se desvíe:

Guardia	Por qué existe (evidencia)
Sin fragmentos → **"No sé" literal** y requires_human	Si la herramienta no devolvió nada, cualquier respuesta sería inventada.
Abstención parafraseada → **"No sé" literal** ("el manual no especifica…", "no hay información…")	Ejecución 358: el modelo dijo correctamente que el manual no trae el plazo, pero con otras palabras y agregando consejos.
Citas validadas: se descartan secciones que la herramienta no devolvió (`cita_sin_respaldo`)	Ejecución 188: Tech Support citó "sección 2.1" sin haber consultado el manual.
Cita obligatoria: si usó secciones y no las nombra, se agrega "(Manual de soporte, sección X)"	Ejecución 366: respuesta correcta sin cita.

Cada respuesta deja trazado qué consultó el agente (`consultas_rag`), qué fragmentos recibió con su score (`fragmentos`) y qué citó (`fuentes`); el manager lo vuelca al log de trazabilidad.

Pieza 4 · Pruebas ciegas con sinónimos

5 preguntas escritas como las escribiría el dueño de un local, **sin usar las palabras del manual** ("celu", "trabado en caja", "cada uno lo suyo", "abono"). Corridas de punta a punta por el manager M5 (Chat Trigger → router → worker → herramienta), sobre la versión final, el 11/10/2026.

Pregunta (sinónimo)	Fragmento recuperado (sección · score)	Respuesta del agente	Veredicto
¿Mis clientes tienen que instalarse algo en el **celu** para poder pedir? Ejec. 375 · Tech Support	3.1 (0,54) · **4.2 (0,53)** · **3.2 (0,51)** · 1.2 (0,51) 3.2: "el cliente no descarga ninguna aplicación ni se registra…"	Los clientes no necesitan instalar ninguna aplicación en su celular. Solo escanean el código QR de la mesa y acceden al menú directamente desde el navegador. (Manual de soporte, secciones 3.2 y 4.2)	Correcta
Un cliente pagó con Mercado Pago pero en la tablet el pedido sigue **trabado en caja**, ¿qué hago? Ejec. 378 · Billing	**14.6 (0,63)** · 5.5 · 6.2 · 7.1 14.6: "tocar 'Refrescar Estado MP' en la tarjeta del pedido…"	Si el pedido sigue en "En Caja" después de que el cliente pagó con Mercado Pago, tocá "Refrescar Estado MP" en la tarjeta del pedido. Esto consulta el pago directamente en Mercado Pago y, si está aprobado, lo registra y pasa el pedido a Pendiente. (sección 14.6)	Correcta
Somos cuatro en la mesa y queremos **pagar cada uno lo suyo**, ¿se puede? Ejec. 381 · Billing	**8.1 (0,59)** · 8.3 · **8.2 (0,54)** · 8.5 8.2: pago total, partes iguales, por ítems, monto personalizado	Sí, en ProTable se puede dividir la cuenta para los pedidos en mesa. Cada comensal puede elegir si paga el total o una parte… Las opciones incluyen pagar por ítems, partes iguales o un monto personalizado (secciones 8.1 y 8.2).	Correcta
¿Cuánto me sale el **abono más básico** y hasta cuántas mesas cubre? Ejec. 384 · Sales	**2.1 (0,48)** · 4.4 · 2.2 · 2.3 2.1: "Starter · $25.000 por mes · hasta 15 mesas…"	El abono más básico, llamado Starter, cuesta $25.000 por mes y cubre hasta 15 mesas. Incluye menú QR, pedidos, pantalla de cocina y soporte por email (sección 2.1).	Correcta
Tengo el plan Pro con soporte prioritario: **¿en cuántas horas** me tienen que responder un reclamo? Ejec. 387 · Tech Support · **prueba "No sé"**	15.2 (0,67) · 3.11 · 2.1 · 2.2 · 15.3 · 14.6 (2 consultas × Top-4 = 6 fragmentos únicos) 15.2: "El plan Pro incluye soporte prioritario" (sin plazo)	No sé: esa información no está en el manual de soporte de ProTable. Tu caso pasa a una persona del equipo, que lo va a revisar.	Correcta (abstención)

5 / 5 = 100 %
Precisión de respuesta (4 respuestas fieles al manual con cita + 1 abstención correcta).

4 / 4
Recuperación: en las 4 preguntas que el manual responde, la sección correcta aparece en el Top-4.

0
Alucinaciones en la versión final (ningún dato fuera de los fragmentos).

Análisis de fallas (encontradas al construir y corregidas antes de la corrida final)

Falla observada	Causa	Corrección
"¿Me cobran un porcentaje de lo que vendo?" → "No sé" (ejec. 192)	Sinónimo: el manual dice "comisión"; la búsqueda solo vectorial dio 0,34 a la 2.2.	Búsqueda híbrida + instrucción de reformular con el vocabulario del manual (ejec. 242: responde "sin comisión", sección 2.2).
Pregunta sobre plazos del soporte → derivada a humano sin consultar (ejec. 356/357)	El router la clasificaba UNKNOWN: su taxonomía no contemplaba preguntas sobre el producto o el soporte.	Taxonomía ampliada: van a Tech Support, que sí consulta el manual.
Abstención correcta pero no literal, con consejos (ejec. 358)	El modelo parafrasea la regla.	Guardia de abstención en código (ejec. 362 y 387: "No sé" literal).

Tech Support citó "sección 2.1" sin consultar y registró un ticket P1 por un problema documentado (ejec. 188)	La regla de ticket ("LLAMÁ registrar_ticket") pesaba más que la de consultar.	"PRIMERO consultá el manual; si figura en Problemas frecuentes, respondé sin ticket" + validación de citas.
La herramienta devolvía "Workflow is not active" (ejec. 188)	n8n no ejecuta sub-workflows sin publicar.	Herramienta y workers publicados. El agente, sin fragmentos, respondió "No sé" (fallo seguro).

Riesgo residual: "abono" (sinónimo de plan) recuperó la 2.1 con 0,48 en la corrida final y con 0,41 en una anterior: cerca del corte. Un sinónimo más lejano podría quedar afuera → el agente diría "No sé" (fallo seguro, no alucinación). Mitigación prevista: glosario de sinónimos en la ingesta (plan = abono = suscripción).

Pieza 5 · Plan de gobernanza de la base de conocimiento

Tema	Regla
Dueño del contenido	El responsable del manual (figura en la sección 0) es el único que aprueba cambios. El agente nunca escribe en la base: solo lee.
Qué entra al manual	Solo información verificada del producto (FAQ público, condiciones comerciales vigentes, documentación funcional). Quedan afuera los Términos y Condiciones y la Política de Privacidad hasta que tengan validación legal, y toda función que no exista (por ejemplo, facturación electrónica).
Versionado	Cada versión lleva número y fecha de vigencia; cada fragmento guarda `version_manual` y el resultado del parseo se archiva en el repo (la consola de LlamaCloud lo borra a las 48 h). Precios y planes cambian solo con una versión nueva del manual.
Actualización	Editar el manual → regenerar el PDF → ejecutar `M5_ingesta_manual_llamacloud`, que vacía la tabla y la vuelve a cargar completa (idempotente: no quedan fragmentos viejos mezclados).
Prueba antes de publicar	Toda versión nueva corre el banco de regresión: las 27 consultas de calibración y las 5 preguntas ciegas. Se publica solo si las preguntas con respuesta siguen sobre 0,40 y las de "No sé" siguen en "No sé".
Revisión periódica	Mensual, y siempre que cambien precios, planes o una pantalla del producto. Se revisan las respuestas "No sé" del mes: si una pregunta se repite, es contenido que falta en el manual.
Monitoreo	Desde el log de trazabilidad: tasa de "No sé", respuestas con `cita_agregada` o `abstencion_normalizada` (el modelo se desvió y la guardia corrigió), mejor score por consulta, y casos derivados a humano.
Parámetros fijos	Top-K, Minimum Score y pesos de la búsqueda viven en el sub-workflow, no en el prompt: el agente no puede pedir más fragmentos ni bajar el umbral. Cambiarlos exige recalibrar y dejar la nueva tabla de calibración.
Privacidad	La base contiene solo información pública del producto, sin datos de clientes. Las consultas viajan a OpenAI para el embedding y la respuesta; antes de procesar datos reales se revisa la política de retención del proveedor.
Costo	Ingesta: 42 créditos de LlamaParse (plan gratis: 10.000/mes) + 91 embeddings. Cada consulta: 1 embedding + 1–2 llamadas a gpt-4o-mini. Si se pasa al índice de LlamaCloud (plan Starter, USD 50/mes), se cambia solo el sub-workflow.

Cómo probarlo

En n8n, carpeta **M5**: abrir `checkpoint5_bruno_acorsi` → **Open chat** → escribir una de las preguntas de la Pieza 4. El manager M5 queda **sin publicar** a propósito: comparte la casilla de Gmail con el M4, que está publicado, y los dos procesarían el mismo email. Para pasar a producción: despublicar el M4 y publicar el M5.