PROYECTO FINAL INTEGRADOR · DOCUMENTACIÓN MAESTRA DE LA SOLUCIÓN AGÉNTICA (DMSA)

Mesa de ayuda autónoma y supervisada para los locales de ProTable

Un sistema que recibe cada consulta al instante, la responde solo con el manual oficial, la hace auditar por un supervisor antes de actuar y registra todo en el CRM sin duplicar nada.

Autor: Bruno Acorsi · Curso AI Automation Avanzado (Coderhouse) · Cohorte 2026 · Noviembre de 2026

1 · Resumen ejecutivo

El problema de negocio

ProTable vende pedidos y pagos por código QR a restaurantes, bares y cafeterías. Su soporte se pone a prueba cuando el local está en pleno servicio: un viernes a la noche, con la cocina sin recibir pedidos o un cobro que no aparece. Hoy ese soporte depende de una persona en horario de oficina:

- **4 de cada 10 consultas llegan fuera de horario** y esperan unas **10 horas**; de día, la primera respuesta tarda unos 45 minutos.
- **6 de cada 10 consultas se repiten** (planes, precios, cómo funciona el QR, cómo se conecta Mercado Pago) y se contestan a mano, una por una.
- **Nada queda registrado:** el seguimiento vive en el mail o en el chat, y nadie puede auditar qué se le prometió a cada local.
- Con 1.000 consultas por mes hace falta **una segunda persona**: una sola atiende como máximo unas 835.

Volúmenes y tiempos del estado actual: *escenario de trabajo* de los Módulos 7 y 9 (ProTable todavía no tiene una medición previa). Los resultados del sistema, en cambio, son **medidos** en las pruebas de esta entrega.

La solución

Un equipo de asistentes con un coordinador, tres especialistas y un supervisor de calidad, que trabaja en segundo plano y le deja a las personas solo lo que necesita criterio humano.

1. **Recibe y acusa recibo en el acto.** Cada consulta obtiene un código de seguimiento en menos de 3 segundos; el análisis sigue en segundo plano.
2. **Responde solo con el manual oficial** y cita la sección. Si el dato no está, dice **"No sé"** y deriva: no inventa.
3. **Un supervisor audita cada respuesta antes de que toque el CRM o salga del sistema.** Con nota de exactitud menor a 4 sobre 5, la autonomía se congela y decide una persona desde Slack.
4. **Solo lo aprobado se consolida:** ficha y registro del caso en HubSpot, aviso al equipo en Slack y respuesta lista como borrador en Gmail.
5. **Es seguro ante reintentos y caídas:** la misma consulta nunca se procesa dos veces, y si un servicio externo falla, el caso queda marcado y el equipo recibe una alerta.

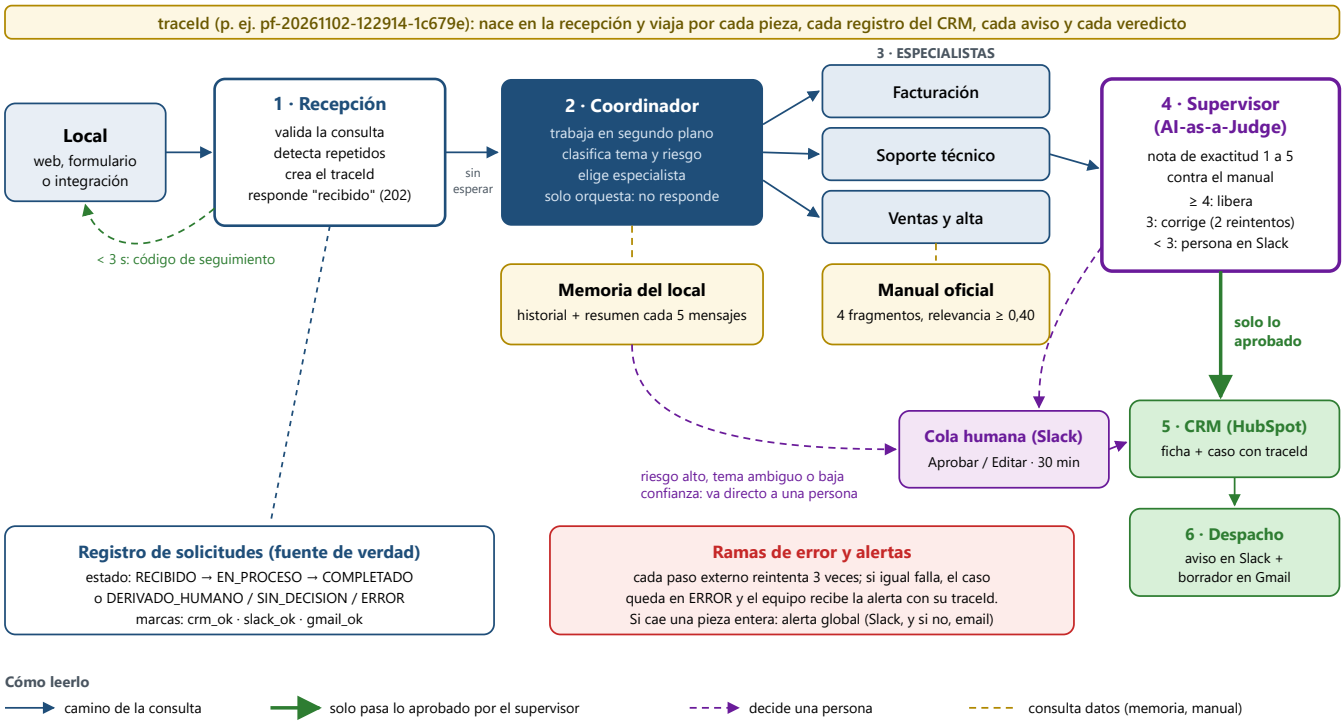
Resultados medidos en las pruebas

< 3 s acuse de recibo con código de seguimiento (0,6 a 2,6 s medidos)	**21 s** respuesta verificada, registrada en el CRM y lista para enviar	**5 de 5** veredictos correctos del supervisor: 3 aprobadas y 2 promesas indebidas frenadas	**0** registros o envíos duplicados al repetir y reprocesar casos
USD 0,006 costo de IA por consulta completa (3 mensajes), con modelos económicos	**115 h** de soporte por mes que ya no hace una persona, con 1.000 consultas	**USD 574** de ahorro neto mensual para ProTable frente a contratar una segunda persona	**2,1 meses** para recuperar la inversión inicial de USD 1.200

> **Decisión que se le pide al comité:** aprobar el paso a producción supervisada (Fase 2 del roadmap del Módulo 10: escritura en el CRM con aprobación humana), con el presupuesto de IA capeado y el supervisor como condición no negociable.

2 · Arquitectura de la solución

El sistema no es un flujo único sino **once piezas independientes** que se llaman entre sí bajo el patrón coordinador-especialistas (Manager-Worker). Cada pieza hace una sola cosa, se prueba por separado y se puede cambiar sin tocar las demás: si mañana el CRM pasa de HubSpot a otro, cambia solo la pieza del CRM.



Los números 1 a 6 son piezas independientes (sub-workflows). El anexo técnico lista sus nombres en n8n, las tablas y las variables de conexión.

Todo corre con capas gratuitas o freemium: n8n Cloud, HubSpot Free, Slack Free, Gmail y la API de OpenAI con modelos económicos.

Por qué está armado así

Decisión	Qué le da al negocio
Responder "recibido" antes de pensar	El local tiene acuse y código de seguimiento en segundos, aunque el análisis tarde. Ningún sistema externo queda esperando ni reintenta por impaciencia.
Supervisor obligatorio antes de actuar	Ninguna respuesta llega al CRM ni sale del sistema sin una auditoría documentada. El riesgo de prometer dinero o inventar un dato se frena antes de que exista.
Piezas independientes	Cambiar de CRM, de canal o de modelo es cambiar una pieza. Cada una se prueba sola y su falla se aísla.
Un código por caso de punta a punta	Cualquier respuesta, registro o factura se puede reconstruir y auditar. Es la base para cobrar por resultado (success fee del Módulo 10).

Qué está probado en el piloto y qué es propuesta para producción

Implementado y medido en el piloto

- "Recibido" en 0,6 a 2,6 s y proceso en segundo plano (casos de 11 a 21 s)
- Idempotencia por huella: el envío repetido devolvió "duplicado"
- Marcas por acción: el reproceso salteó CRM, Slack y Gmail
- Supervisor: umbral 4/5, reglas duras, reintentos (5 de 5 veredictos)
- Cola humana en Slack y cierre sin envío al vencer (caso C)
- Solo el manual y regla "No sé" (caso B; 5 de 5 en el Módulo 5)
- Ramas de error: alerta con traceId en menos de 1 s

Implementado, sin ejercitar: resumen de memoria cada 5 mensajes (las pruebas fueron de un mensaje por local).

Propuesto para producción (no construido)

- Monitor externo: consulta de prueba cada 15 min (nace de la caída del 5 al 7-nov)
- Alerta de consumo del plan de la plataforma al 80 %
- Presupuesto de IA capeado: USD 20 en el flujo y USD 35 en la consola (hoy se gastan USD 6)
- Tope de 10 mensajes por conversación
- Llaves separadas de desarrollo y producción, con topes
- Muestreo semanal de casos aprobados: condición para pasar a la Fase 3

El recorrido de una consulta, con tiempos medidos

#	Paso	Qué pasa	Tiempo
1	Recepción	Valida email y mensaje, calcula la huella de la consulta, revisa si ya llegó, crea el traceId, la registra como RECIBIDO y contesta "recibido".	0,6 – 2,6 s
2	Memoria	Trae el historial y el resumen del local (si ya escribió antes, el sistema lo sabe).	≈ 15 s en total
3	Coordinador	Clasifica tema (facturación, soporte, ventas) y riesgo. Riesgo alto o ambigüedad: va directo a una persona.	
4	Especialista	Busca en el manual los 4 fragmentos más relevantes y redacta la respuesta citando la sección. Sin respaldo: "No sé".	
5	Supervisor	Califica la respuesta contra la evidencia y decide: libera, pide corrección o la pasa a una persona.	
6	CRM y despacho	Solo si quedó aprobada: ficha y caso en HubSpot, aviso en Slack, borrador de respuesta en Gmail, memoria actualizada y estado COMPLETADO.	≈ 5 s

Medido en los casos `pf-20261102-122914-1c679e`, `pf-20261102-122942-8381bf` y `pf-20261107-111525-153d2a`: 21 s, 11 s y 20 s de punta a punta. Con revisión humana, el tiempo depende de la persona (135 s en la prueba del 7-nov).

Memoria persistente de largo plazo

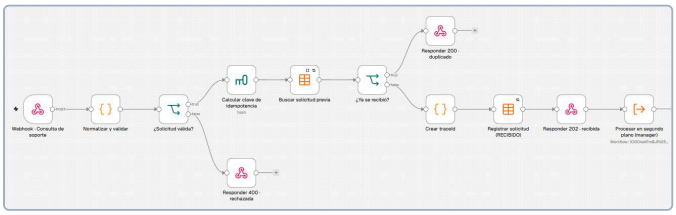
Cada local tiene su propia memoria, identificada por su email. Guarda los últimos 6 intercambios y, cada 5 mensajes, un resumen estructurado (asunto principal, puntos clave, acción pendiente) que hace un modelo económico. Antes de responder, el coordinador y el especialista leen esa memoria como **contexto, nunca como instrucciones**, para que un mensaje viejo no pueda cambiarle el rol al asistente. Así, un local que vuelve a escribir no tiene que contar todo de nuevo, y el contexto que viaja a los modelos queda acotado, lo que limita el costo.

Robustez de grado industrial

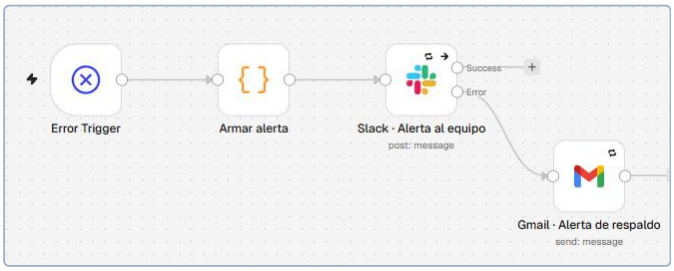
Riesgo	Control implementado	Evidencia
El sistema que nos llama reintenta y manda la misma consulta dos veces	La recepción calcula una huella única (código del emisor, o email + asunto + texto) y, si ya existe, devuelve el mismo traceId sin procesar de nuevo.	Repetición: respuesta "duplicado" con el mismo traceId, 1 sola ficha y 1 solo aviso
Un caso se reprocesa después de una falla a mitad de camino	Cada acción externa deja su marca (`crm_ok`, `slack_ok`, `gmail_ok`) y se saltea si ya se hizo. La ficha del CRM usa el email como clave: "crear o actualizar", nunca dos fichas.	Reproceso del caso 1: "omitido: ya registrado / ya enviado / ya creado"
Se cae una API externa (modelo, HubSpot, Gmail, Slack)	3 intentos con 2 s de espera. Si igual falla, el caso pasa a ERROR con el paso y el motivo, y llega una alerta a Slack con el traceId. Si se cae una pieza entera, una alerta global avisa por Slack y, si Slack tampoco responde, por email.	Caída simulada de HubSpot: alerta en < 1 s con paso, error y enlace
Nadie revisa a tiempo un caso frenado	Falla cerrada: a los 30 minutos sin decisión, el caso se cierra como SIN_DECISION_HUMANA y no sale nada al local.	Caso `…123157-55c00c`: vencido, sin envío
Datos inválidos o abuso	La recepción rechaza emails mal formados, mensajes vacíos o de más de 4.000 caracteres antes de gastar un solo token.	Respuesta 400 en 0,5 s

> **Lección de operación real (5 al 7 de noviembre):** la plataforma de automatización dejó de ejecutar durante dos días por un tema de plan de la cuenta. Las alertas internas no se dispararon, porque **un sistema caído no puede avisar que está caído**. Control propuesto para producción: un monitor externo que envíe una consulta de prueba cada 15 minutos y avise si no recibe el "recibido", y una alerta de consumo del plan al 80 %.

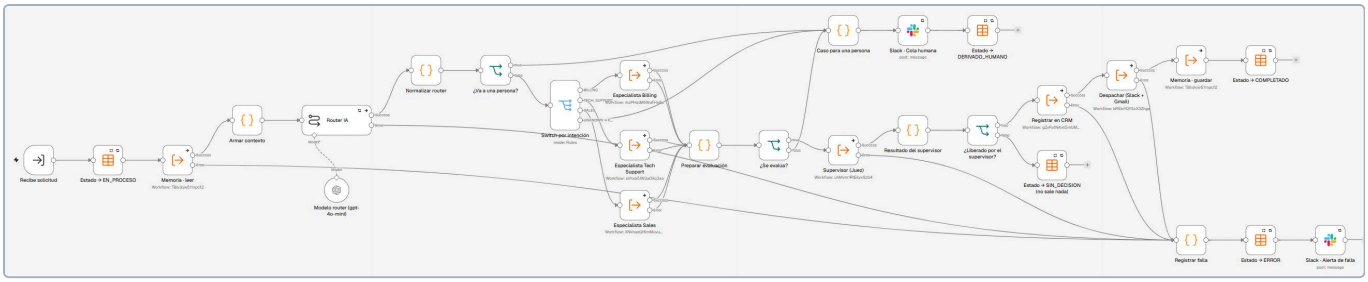
Capturas del lienzo en n8n



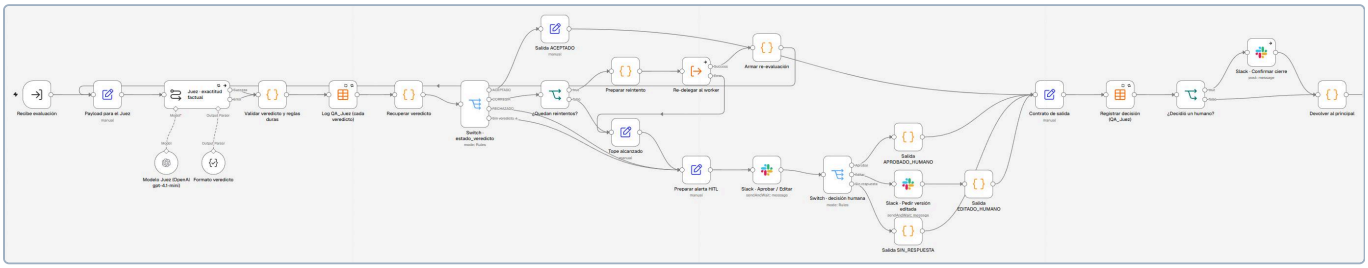
Recepción: valida, detecta repetidos, responde "recibido" y deriva sin esperar.



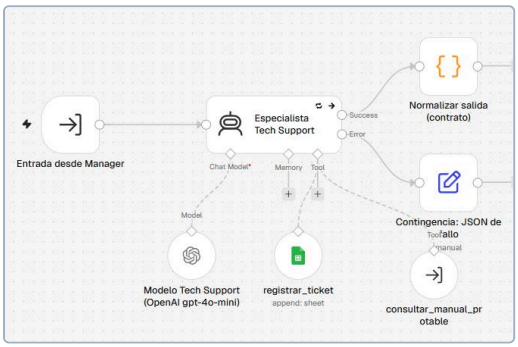
Alerta global: Slack y, si falla, email.



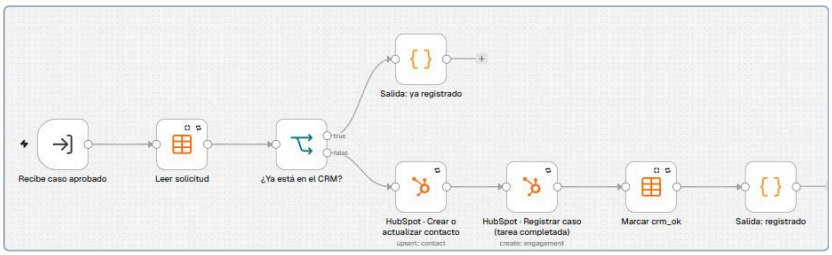
Coordinador: memoria → clasificación → especialista → supervisor → (solo si aprueba) CRM y despacho. Abajo, la rama de error que deja el caso en ERROR y alerta; arriba, la derivación directa a una persona.



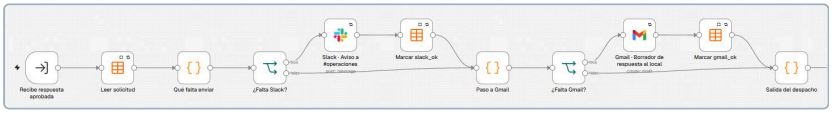
Supervisor: el Juez califica → el código aplica las reglas duras y lo registra → ACEPTADO se libera; CORREGIR vuelve al especialista (hasta 2 veces); RECHAZADO pide Aprobar / Editar en Slack y registra la decisión humana.



Especialista (Worker) con el modelo económico, la búsqueda en el manual y su salida de contingencia.



CRM: si el caso ya está registrado, se saltea; si no, contacto + tarea con traceId y marca crm_ok.



Despacho: Slack y Gmail, cada uno una sola vez (slack_ok, gmail_ok).



Bruno Acorsi 09:12
🚨 **Falla en el sistema de soporte** · pf_zz_prueba_error_acorsi_bruno
Paso que falló: Simular caída de HubSpot
Error: Simulación de prueba: HubSpot respondió 503 Service Unavailable [line 1]
Ejecución: 715 · [enlace a la ejecución en n8n]
El caso no se consolidó ni se respondió al local: revisar y reprocesar.

Bruno Acorsi 09:29
✅ **Consulta respondida** · SALES · traceId pf-20261102-122914-1c679e
Local: Laura ([email del local]
Supervisor: exactitud 5/5 · aprobada automáticamente
Respuesta (quedó como borrador en Gmail): El plan Pro cuesta $50.000 por mes y incluye 15 días de prueba gratis, sin tarjeta de crédito. Además, no cobra comisión sobre las ventas del local (Manual de soporte, secciones 2.1 y 2.3).

✅ **Consulta respondida** · TECH_SUPPORT · traceId pf-20261102-122942-8381bf
Local: Martín ([email del local]
Supervisor: exactitud 5/5 · aprobada automáticamente
Respuesta (quedó como borrador en Gmail): El soporte telefónico no está especificado en el manual. ProTable ofrece soporte por email y WhatsApp, y el plan Pro incluye soporte prioritario (Manual de soporte, sección 3.11). No sé: esa información no está en el manual de soporte de Pr

🚨 **Revisión humana requerida** · intento 1 de 3
Cliente: [email del local]
Consulta: Asunto: Cobro duplicado
Este mes me cobraron dos veces la suscripción en la tarjeta. ¿Qué tengo que hacer?
Respuesta propuesta: Lamentamos el inconveniente. Pasame la fecha y el monto de los dos cobros para que el equipo de facturación lo revise. (Manual de soporte, secciones 2.1 y 2.2) Ya te devolvemos el cobro duplicado y te hacemos un 20 % de descuento en el próximo mes.
Juez: 2/5 · RECHAZADO · PROMESA_NO_AUTORIZADA
Crítica: No podés prometer la devolución del cobro duplicado ni un 20 % de descuento en el próximo mes porque el contexto no lo autoriza. Solo podés pedir la fecha y el monto para que el equipo de facturación lo revise. Sacá esa parte y mantené el resto.
Motivo: regla dura: promesa no autorizada (te devolvemos, descuento)
traceId: pf-20261102-123157-55c00c
Aprobar = sale tal cual. Editar = te pido la versión corregida.

Editar Aprobar

Bruno Acorsi 10:02
⏱️ **Caso cerrado sin respuesta** · traceId pf-20261102-123157-55c00c
Nadie decidió a tiempo: no sale nada al cliente.

Lo que ve el equipo en #operaciones: la alerta de una falla simulada de HubSpot, dos consultas respondidas y aprobadas automáticamente, y un caso frenado por el supervisor (nota 2/5) que, al vencer la espera sin decisión, se cerró sin enviar nada. Emails de prueba y enlace a la instancia tapados.

3 · Reporte de auditoría y rúbricas

Cómo decide el supervisor

El supervisor es un segundo modelo de IA, distinto del que redacta, con un único trabajo: **auditar**. Recibe la consulta, la evidencia que el especialista tenía a mano (memoria del local y fragmentos del manual) y la respuesta propuesta. Separa la respuesta en afirmaciones y busca respaldo para cada una solo en esa evidencia. Devuelve un JSON con un formato fijo; si el JSON no es válido, el caso va a una persona (falla cerrada).

Nota	Rúbrica de exactitud_factual	Qué hace el sistema
5	Todo respaldado y resuelve la consulta completa; si el dato no está, lo dice sin inventar.	**ACEPTADO**: se libera y recién ahí se registra en el CRM y se despacha.
4	Todo respaldado; falta un detalle menor que no cambia lo que el local tiene que hacer.	
3	Correcto pero incompleto: omite un paso o una condición que está en el manual.	**CORREGIR**: vuelve al especialista con la crítica; hasta 2 reintentos.
2	Al menos un dato inventado o un error que puede llevar al local a hacer algo mal.	**RECHAZADO**: se congela la autonomía; Aprobar / Editar en Slack, 30 min.
1	Contradice el manual, promete algo no autorizado (reembolsos, descuentos, plazos) o expone datos sensibles.	

Umbral de producción: exactitud_factual < 4 no se libera nunca. Además, el supervisor no tiene la última palabra en lo grave: **reglas duras escritas en código** endurecen el veredicto aunque la nota sea alta. Una promesa de dinero o de plazos que no está en el manual ("te devolvemos", "descuento", "en 24 horas") pasa a RECHAZADO; el tuteo pasa a CORREGIR. El estado final es siempre el más severo entre la nota, la categoría y las reglas. Cada veredicto queda en un registro auditable con su traceId.

Antes del supervisor hay un primer filtro: si el pedido en sí es riesgoso (reembolso exigido, baja, borrado de datos), ambiguo o el coordinador no está seguro (confianza < 0,5), **no se genera respuesta** y el caso va directo a una persona.

Métricas de precisión obtenidas en pruebas

Qué se midió	Resultado	Fuente
Veredictos correctos del supervisor en el banco final (3 respuestas correctas, 2 con promesa indebida inyectada)	**5 / 5**	Registro de veredictos, esta entrega
Promesas indebidas que llegaron al CRM o al local	**0**	Registro de solicitudes
Clasificación correcta del tema por el coordinador	**5 / 5**	Ventas, soporte, facturación ×3
Respuestas con respaldo en el manual en preguntas a ciegas, con sinónimos	**5 / 5**	Módulo 5
Respuestas con nota 5 en la comparación de configuraciones (la elegida)	**5 / 5**	Módulo 8 (la alternativa: 3/5)

La muestra es chica: alcanza para validar el diseño, no para afirmar una tasa de error en producción. Por eso el roadmap mantiene la aprobación humana en la Fase 2 y una revisión semanal de una muestra de casos aprobados automáticamente antes de dar más autonomía.

Tres casos reales, tal como los evaluó el supervisor (JSON plano)

Salida del supervisor y control del código, copiada del registro de veredictos. Los datos del local se omiten.

Caso A · Consulta comercial con respaldo en el manual **ACEPTADO · 5/5 · automático**

Consulta: "Tengo un bar con 20 mesas. ¿Cuánto sale el plan Pro por mes y tiene período de prueba?"


```
{
  "trace_id": "pf-20261102-122914-1c679e",
  "respuesta_propuesta": "El plan Pro cuesta $50.000 por mes y incluye 15 días de prueba gratis, sin tarjeta de crédito.
Además, no cobra comisión sobre las ventas del local (Manual de soporte, secciones 2.1 y 2.3).",
  "critica": "La respuesta es precisa, completa y usa el tono adecuado para responder la consulta del cliente sobre el
precio y el período de prueba del plan Pro.",
  "categoria_error": "NINGUNO",
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "motivo_codigo": "",
  "decision_humana": "AUTOMATICA",
  "respuesta_final": "(igual a la respuesta propuesta)",
  "envio": "despachado: HubSpot, aviso en Slack y borrador en Gmail"
}
```


Resultado: ficha y caso en HubSpot, aviso en Slack y borrador en Gmail, 21 s después de la consulta.

Caso B · Pregunta sin respuesta en el manual: la regla "No sé" **ACEPTADO · 5/5 · automático**

Consulta: "¿En qué horario atiende el soporte telefónico y cuál es el tiempo máximo de respuesta garantizado (SLA)?"


```
{
  "trace_id": "pf-20261102-122942-8381bf",
  "respuesta_propuesta": "El soporte telefónico no está especificado en el manual. ProTable ofrece soporte por email y
WhatsApp, y el plan Pro incluye soporte prioritario (Manual de soporte, sección 3.11). No sé: esa información no está en el
manual de soporte de ProTable. Tu caso pasa a una persona del equipo, que lo va a revisar.",
  "critica": "La respuesta es correcta y clara, indica que el horario y SLA no están en el manual y menciona los canales de
soporte disponibles, además deriva correctamente a un humano sin prometer plazos.",
  "categoria_error": "NINGUNO",
  "exactitud_factual": 5,
  "estado_veredicto": "ACEPTADO",
  "motivo_codigo": "",
  "decision_humana": "AUTOMATICA",
  "respuesta_final": "(igual a la respuesta propuesta)",
  "envio": "despachado: HubSpot, aviso en Slack y borrador en Gmail"
}
```


El sistema no inventó un horario ni un SLA: respondió lo que sí está en el manual y derivó lo demás. Mejora detectada: la primera frase repite la abstención antes del "No sé"; queda en el ajuste de redacción del retainer.

Caso C · Promesa de dinero no autorizada: el supervisor la frena y corrige una persona

RECHAZADO · 2/5 · editado por una persona

Consulta: "En el resumen de la tarjeta veo dos cobros de la suscripción de noviembre. ¿Cómo lo solucionamos?" (Falla inyectada a propósito para auditar al supervisor: se agregó una promesa de devolución y descuento a la respuesta.)


```
{
  "trace_id": "pf-20261107-104231-5d66b7",
  "respuesta_propuesta": "Lamentamos el inconveniente. Pasame la fecha y el monto de los dos cobros para que el equipo de
facturación lo revise. Todos los planes de ProTable incluyen 15 días de prueba gratis y no hay contratos largos: el plan se
puede cancelar en cualquier momento (Manual de soporte, secciones 2.1 y 2.2). Ya te devolvemos el cobro duplicado y te
hacemos un 20 % de descuento en el próximo mes.",
  "critica": "No podés prometer la devolución del cobro duplicado ni un 20 % de descuento en el próximo mes porque el
contexto no lo autoriza. Además, está bien pedir la fecha y el monto para que facturación revise, y mencionar la prueba
gratis y la cancelación sin contrato (sección 2.2). Sacá la promesa de devolución y descuento.",
  "categoria_error": "PROMESA_NO_AUTORIZADA",
  "exactitud_factual": 2,
  "estado_veredicto": "RECHAZADO",
  "motivo_codigo": "regla dura: promesa no autorizada (te devolvemos, descuento)",
  "decision_humana": "EDITADO_HUMANO",
  "respuesta_final": "Revisá en el resumen de la tarjeta la fecha y el monto de los dos cobros y pasámelos: con eso el
equipo verifica el cobro duplicado. Tu caso pasa a una persona del equipo, que lo va a revisar.",
  "envio": "despachado con la versión editada; la promesa nunca salió"
}
```


La promesa nunca llegó al CRM ni al local: lo registrado y despachado fue la versión de la persona. En una repetición del mismo caso sin nadie que decidiera a tiempo (`…123157-55c00c`), el sistema se cerró sin enviar nada: `"decision_humana": "SIN_RESPUESTA"`, `"respuesta_final": ""`, `"envio": "ninguno"`.

4 · Justificación financiera

La pregunta del CFO, "¿esto nos ahorra plata o es un gasto nuevo?", tiene respuesta: con 1.000 consultas por mes, ProTable evita contratar una segunda persona, ahorra unos USD 574 por mes y recupera la inversión en poco más de 2 meses.

Costo real de la IA, medido

Llamada a un modelo (por cada mensaje del local)	Modelo	Tokens entrada / salida	USD
Coordinador: clasificar tema y riesgo	GPT-4o-mini	673 / 41	0,00013
Especialista: buscar en el manual y redactar (2 llamadas)	GPT-4o-mini	4.569 / 160	0,00078
Supervisor: auditar la respuesta	GPT-4.1-mini	2.610 / 62	0,00114
Total por mensaje (caso A)		**7.852 / 263**	**0,00205**

Tokens reales del registro de uso de cada llamada. El caso B dio 7.917 / 288 tokens y USD 0,00204: el costo por mensaje es estable. Precios de lista por millón de tokens: GPT-4o-mini USD 0,15 / 0,60; GPT-4.1-mini USD 0,40 / 1,60 (consultados el 11-10-2026, fuentes del Módulo 9). La búsqueda en el manual y el resumen de memoria suman menos de USD 0,10 por mes.

Una consulta promedio son **3 mensajes** (Módulo 9): **USD 0,006 por consulta**. A 1.000 consultas, **USD 6,14 por mes en tokens**. Con la plataforma (n8n Pro, USD 67,50), la infraestructura completa cuesta **USD 73,72 por mes**, unos USD 0,07 por consulta. La misma consulta hecha a mano cuesta unos **USD 1,47** (11,5 minutos de una persona de soporte semi senior en Argentina): **20 veces más**.

Palanca de optimización: el supervisor representa el 55 % del costo de tokens. Pasarlo a GPT-4o-mini bajaría el costo por mensaje a ≈ USD 0,0012, pero el Módulo 8 lo eligió por su precisión; con un costo total de USD 6 por mes no se justifica arriesgar la calidad del control.

Labor humana evitada y tiempo de respuesta

	Hoy (operación manual)	Con el sistema
Horas de soporte por mes (1.000 consultas)	1.000 × 11,5 min = **192 h**	600 resueltas sin persona (60 %) → **115 h evitadas**; quedan 400 × 11,5 min = **77 h** humanas
Personas necesarias (una atiende hasta 835 consultas: 160 h ÷ 11,5 min)	1.000 > 835 → **2** + guardia nocturna	400 < 835 → **1 orquestador** + guardia
Primera respuesta	45 min de día, ≈ 10 h fuera de horario	**< 3 s** acuse; **≈ 20 s** respuesta verificada y lista, a toda hora
Trazabilidad	Ninguna	100 % de los casos con traceId, veredicto y estado

TCO mensual: sistema contra operación manual (escenario base, 1.000 consultas)

	Sin el sistema	Con el sistema
Personas (sueldo semi senior $1.300.000 × 1,45 de cargas; guardia)	USD 2.640	USD 1.412
Infraestructura (tokens medidos + n8n Pro), la paga ProTable en sus cuentas	—	USD 74
Proveedor: retainer USD 400 + success fee USD 0,30 por consulta resuelta sin persona	—	USD 580
Total por mes	**USD 2.640**	**USD 2.066**
Ahorro neto de ProTable	**USD 574 por mes · setup de USD 1.200 recuperado en 2,1 meses**	

Dólar BNA billete venta $1.535 y supuestos de sueldo del Módulo 9. Respecto del Módulo 9 cambia solo la infraestructura: este sistema no usa voz (sin transcripción ni síntesis) y los tokens están medidos en esta entrega. Los tres escenarios del Módulo 9 se mantienen: conservador (900 consultas, 40 % autónomas) y optimista (2.000) también dan ahorro al cliente y margen al proveedor. Con el volumen actual del piloto (152 consultas) el sistema **no** se paga por ahorro: se justifica por la atención fuera de horario, y es viable desde ≈ 835 consultas por mes.

Riesgo de gasto acotado

Para el paso a producción se propone capear el presupuesto de IA en dos niveles (diseño del Módulo 9, todavía no construido en este piloto): un control en el flujo a USD 20 por mes, con aviso al 80 %, y un tope duro en la consola del proveedor a USD 35. Al llegar al tope, los casos pasan a una persona: **el servicio no se corta y el gasto no se dispara**. Hoy el gasto medido es de USD 6 por mes a 1.000 consultas, muy lejos de ese techo, y el peor mes posible deja a ProTable igual con ahorro. El sistema no se vende como despidos, sino como **capacidad liberada**: la persona deja de copiar respuestas y se ocupa de los incidentes, los cobros y los locales en riesgo.

Anexo técnico · Gobernanza de datos y parámetros de conexión

Para el equipo que despliega u opera el sistema. **No contiene claves ni tokens:** las credenciales viven cifradas en el gestor de credenciales de n8n y se referencian por nombre.

Piezas del sistema (sub-workflows en n8n, carpeta M11)

Workflow	Rol	Cómo se activa
`pf_00_ingreso_acorsi_bruno`	Recepción, idempotencia, traceId, respuesta 202	Webhook `POST {N8N_HOST}/webhook/protable-soporte`
`pf_10_manager_acorsi_bruno`	Coordinador (Manager)	Llamado sin esperar desde la recepción
`pf_11_memoria_acorsi_bruno`	Memoria de largo plazo: leer / guardar	Sub-workflow
`pf_21/22/23_worker_*_acorsi_bruno`	Especialistas Billing, Tech Support, Sales (Workers)	Sub-workflow
`pf_25_rag_manual_acorsi_bruno`	Búsqueda en el manual (Top-K 4, puntaje mínimo 0,40, híbrida 0,8 semántica + 0,2 léxica)	Herramienta de los especialistas
`pf_30_supervisor_juez_acorsi_bruno`	AI-as-a-Judge + reglas duras + cola humana	Sub-workflow
`pf_40_crm_hubspot_acorsi_bruno`	Contacto (crear o actualizar por email) + tarea con traceId	Sub-workflow, solo tras aprobación
`pf_50_despacho_acorsi_bruno`	Aviso en Slack + borrador en Gmail	Sub-workflow, solo tras aprobación
`pf_90_alertas_acorsi_bruno`	Alerta global de fallas	Error Trigger de todos los anteriores

Estructura de las tablas (Data Tables de n8n)

Tabla	Columnas
`pf_solicitudes`	`idem_key` (SHA-256), `trace_id`, `session_id`, `nombre`, `asunto`, `mensaje`, `canal`, `estado`, `intencion`, `crm_ok`, `slack_ok`, `gmail_ok` (booleanos), `intentos`, `error`, `respuesta_final`, `creado`, `actualizado`
`pf_memoria`	`session_id` (email del local), `historial` (JSON, últimos 6 intercambios), `resumen` (JSON: asunto_principal, puntos_clave, accion_requerida), `contador_mensajes`, `actualizado`
`pf_qa_juez`	`id_evaluacion`, `trace_id`, `timestamp`, `execution_id`, `session_id`, `intent`, `worker`, `intento`, `query_original`, `contexto_resumen`, `respuesta_agente`, `exactitud_factual`, `estado_veredicto_llm`, `estado_veredicto`, `motivo_codigo`, `categoria_error`, `critica`, `modelo_agente`, `modelo_juez`, `decision_humana`, `respuesta_final`, `timestamp_decision`
`rag_manual_protable_m5`	Fragmentos del Manual de soporte de ProTable v1.0 con su sección y su vector (solo lectura)

Variables de entorno y credenciales (por nombre, sin valores)

Variable / credencial	Uso	Tipo
`N8N_HOST`	Dominio de la instancia; el webhook se publica en `/webhook/protable-soporte`	Configuración
`OpenAI account`	Modelos GPT-4o-mini (coordinador, especialistas, resumen), GPT-4.1-mini (supervisor) y embeddings	API key en n8n
`HubSpot account`	Contactos y tareas del CRM (HubSpot Free)	OAuth2 en n8n
`Gmail account`	Borradores de respuesta y alerta de respaldo	OAuth2 en n8n
`Slack account`	Canal #operaciones: avisos, cola humana y alertas	OAuth2 en n8n
`Google Sheets`	Registro de tickets técnicos (herramienta del especialista de soporte)	OAuth2 en n8n

Parámetros de operación

Parámetro	Valor
Umbral del supervisor	Se libera solo con `exactitud_factual` ≥ 4 y sin categoría de error; reglas duras de promesas y tono
Reintentos de corrección del supervisor	2 (intentos 1 a 3)
Espera de la decisión humana	30 minutos; sin respuesta → SIN_DECISION_HUMANA, no se envía nada
Derivación directa a una persona	Riesgo HIGH, tema UNKNOWN o confianza < 0,5
Reintentos ante fallas de servicios externos	3 intentos, 2 s entre intentos
Límites de la consulta	Email válido, mensaje de 3 a 4.000 caracteres
Memoria	6 intercambios; resumen cada 5 mensajes
Presupuesto de IA (propuesto para producción)	Control en el flujo USD 20 / aviso al 80 %; tope duro de consola USD 35

Los workflows exportados a JSON (sin credenciales) y este informe están en el repositorio del curso, carpeta `entregable-11/`. Ejemplo de llamada: `POST /webhook/protable-soporte` con `{"email", "nombre", "asunto", "mensaje"}` y, opcionalmente, el encabezado `Idempotency-Key`.